

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Dokumentacja końcowa projektu ZZSN

Evaluating Diffusion Inversion Methods for Text-Based Image Editing -
Task B

Michał Sadowski, Aleksander Szymczyk

WARSZAWA 2026

1. Opis rozwiązania

Celem projektu było ulepszenie procesu inwersji DDIM[1] dla modelu Stable Diffusion XL [2]. W klasycznym użyciu model dyfuzyjny zaczyna od losowego szumu i wykonuje kolejne kroki odsumiania, aż do otrzymania latentu odpowiadającego obrazowi. Inwersja wykonuje operację przeciwną: dla danego obrazu albo latentu obrazu próbuje odtworzyć taki latent szumowy, z którego ponowne próbkowanie wygeneruje możliwie podobny obraz. Problem polega na tym, że standardowa inwersja DDIM korzysta z przybliżenia lokalnego. Dla przejścia pomiędzy kolejnymi stanami trajektorii zakłada ona, że predykcja szumu obliczona dla czystszy latentu może zastąpić predykcję, którą model otrzymałby dla następnego, bardziej zaszumionego stanu. To przybliżenie jest wygodne obliczeniowo, ale powoduje błąd akumulujący się w kolejnych krokach inwersji.

Zaimplementowane rozwiązanie uczy adapter LoRA[3] dla UNetu modelu SDXL tak, aby poprawić właśnie tę predykcję wykorzystywaną w inwersji. Bazowy model SDXL pozostaje zamrożony i pełni rolę nauczyciela, natomiast trenowane są wyłącznie niskowymiarowe macierze LoRA dodane do warstw uwagi UNetu. Celem uczenia nie jest bezpośrednie przewidywanie kolejnego latentu trajektorii, ale przewidywanie szumu nauczyciela dla następnego, bardziej zaszumionego stanu:

$$\varepsilon_{\phi}(x_{t-1}, t, c) \approx \varepsilon_{\theta}(x_t, t, c),$$

gdzie θ oznacza zamrożony bazowy UNet SDXL, ϕ oznacza UNet z trenowanym adapterem LoRA, x_{t-1} jest czystszy latentem dostępnym w trakcie inwersji, x_t jest odpowiadającym mu bardziej zaszumionym latentem, a c oznacza warunkowanie tekstowe SDXL.

1.1. Przygotowanie danych

Dane treningowe są budowane z promptów pochodzących ze zbioru Recap-COCO[4]. Dla każdego promptu uruchamiane jest próbkowanie modelem `stabilityai/stable-diffusion-xl-base-1.0` z harmonogramem DDIM. Konfiguracja projektu używa obrazów 1024×1024 , 50 kroków inferencji oraz skali guidance[5] równej 1. Dla każdej próbki zapisywany jest obraz końcowy, treść promptu, metadane, lista timestepsów oraz pełna trajektoria latentów w pliku `trajectory.pt`. Trajektoria zapisana jest w kolejności próbkowania: od początkowego szumu do coraz czystszych latentów prowadzących do obrazu.

Oprócz samej trajektorii zapisywane są tensory potrzebne do treningu adaptera. Dla SDXL warunkowanie nie składa się wyłącznie z `prompt_embeds` przekazywanego jako `encoder_hidden_states`. Model wymaga również dodatkowego warunkowania: `pooled_prompt_embeds` oraz `add_time_ids`, przekazywanych do UNetu przez `added_cond_kwargs`. Implementacja zapisuje więc dla każdej próbki plik `conditioning.pt`

zawierający: `prompt_embeds`, `pooled_prompt_embeds` i `add_time_ids`. Dzięki temu podczas treningu nie trzeba ponownie uruchamiać enkoderów tekstu.

Drugim zapisanym elementem jest `target_eps.pt`. Jest to stos predykcji szumu obliczonych przez zamrożony bazowy UNet SDXL dla kolejnych bardziej zaszumionych latentów trajektorii. Dla trajektorii zapisanej jako

$$z_0, z_1, \dots, z_N,$$

gdzie z_0 jest początkowym szumem, a z_N najczystszy latent obrazu, próbka treninowa o indeksie i używa z_{i+1} jako wejścia ucznia i predykcji nauczyciela dla z_i jako celu. Ostatni latent trajektorii nie jest używany jako osobne wejście, ponieważ nie ma po nim kolejnego celu.

1.2. Zbiór treningowy i funkcja straty

Klasa `LatentTrajectoryDataset` traktuje każdą zapisaną trajektorię jako zbiór przejść pomiędzy kolejnymi latentami. Dla pojedynczego elementu zwracane są: czystszy latent `x_clean`, timestep celu, `prompt_embeds`, `pooled_prompt_embeds`, `add_time_ids` oraz zapisany wcześniej `target_eps`. Dzięki temu trening nie musi obliczać celu nauczyciela w każdej iteracji, co zmniejsza koszt pojedynczego kroku.

Podczas treningu UNet z aktywnym adapterem LoRA dostaje czystszy latent oraz ten sam timestep i to samo warunkowanie, które odpowiadają celowi nauczyciela. Strata jest średnim błędem kwadratowym pomiędzy predykcją ucznia a zapisanym celem:

$$\mathcal{L}(\phi) = \|\varepsilon_\phi(z_{i+1}, t_i, c) - \varepsilon_\theta(z_i, t_i, c)\|_2^2.$$

Jest to bezpośrednie dopasowanie do przybliżenia wykorzystywanego przez DDIM inversion: model ma lepiej estymować predykcję dla bardziej zaszumionego stanu, mając dostęp tylko do czystsze latentu.

1.3. Trening adaptera LoRA

Trening został zaimplementowany w klasie `SDXLInversionTrainer`. Pipeline SDXL jest ładowany w trybie `fp16/bf16`, a jego składniki są zamrażane. Adapter LoRA jest wstrzykiwany wyłącznie do UNetu, w warstwach uwagi `to_q`, `to_k`, `to_v` oraz `to_out.0`. Trenowane są tylko parametry LoRA, natomiast bazowe wagi modelu, VAE oraz enkodery tekstu pozostają niezmienione. Takie podejście ogranicza liczbę trenowanych parametrów i pozwala używać adaptera tylko w inwersji, bez wpływania na standardowe generowanie obrazów, jeśli adapter nie zostanie jawnie aktywowany.

W projekcie przygotowano trzy warianty adaptera różniące się rzędem macierzy LoRA: $r = 8$, $r = 16$ oraz $r = 32$. Dla nich ustawiono odpowiednio `lora_alpha` równe 4, 8 i 16. Wspólna konfiguracja treningu używa optymalizatora AdamW[6], współczynnika uczenia

$5 \cdot 10^{-5}$, zerowego weight decay, gradient clipping do wartości 1 oraz harmonogramu cosine z 1000 krokami rozgrzewki. Checkpointy zapisywane są cyklicznie jako same wagi adaptera oraz, opcjonalnie, pełny stan treningu zawierający stan optymalizatora, schedulera i generatorów losowych.

1.4. Użycie adaptera w inwersji i ewaluacja

Wytrenowany adapter jest używany podczas etapu inwersji. Skrypt ewaluacyjny ładuje zapisany latent końcowy obrazu, koduje prompt, aktywuje LoRA w UNecie i wykonuje DDIM inverse scheduler, zapisując odtworzony latent szumowy `inverted_noise.pt`. Następnie osobny etap rekonstrukcji startuje z tego latentu szumowego i wykonuje zwykłe próbkowanie DDIM do obrazu `reconstructed.png`. W konfiguracji ewaluacji rekonstrukcja może być uruchomiona z wyłączonym adapterem LoRA, aby odizolować wpływ adaptera na samą inwersję, a nie na standardowy proces generowania.

Raport ewaluacyjny porównuje odtworzony szum z oryginalnym początkowym szumem trajektorii oraz obraz zrekonstruowany z obrazem końcowym zapisanym podczas generowania danych. Liczone są między innymi metryki MSE, RMSE, MAE, PSNR i SSIM dla obrazów, statystyki błędu latentów, podobieństwo odtworzonego szumu do rozkładu normalnego oraz wizualizacje błędów obrazu. Taka ewaluacja sprawdza więc dwa aspekty rozwiązania: czy LoRA poprawia odtworzenie latentnego szumu oraz czy po ponownym próbkowaniu zachowany jest obraz, od którego zaczęła się inwersja.

Kod źródłowy projektu:

<https://github.com/AtarSander/Diffusion-Inversion-for-Image-Editing>

2. Wyniki eksperymentów

Celem eksperymentów było sprawdzenie, czy adapter LoRA uczony do korekty predykcji szumu może poprawić jakość inwersji DDIM. Ocena została przeprowadzona w trzech aspektach: podobieństwa odtworzonego szumu do rzeczywistego szumu początkowego, jakości rekonstrukcji obrazu oraz przydatności uzyskanych latentów w edycji tekstowej. Szczególnie istotne było sprawdzenie, czy poprawa własności latentów nie odbywa się kosztem rekonstrukcji obrazu.

Zbiór ewaluacyjny obejmował 1522 próbki walidacyjne ze zbioru recap-coco przygotowane analogicznie do danych treningowych.

Porównanie wykonano względem standardowej DDIM inversion. Dodatkowo uwzględniono warianty, w których adapter LoRA był aktywny tylko przez pierwsze kroki inwersji, ponieważ zgodnie z założeniami projektu największy błąd aproksymacji powinien pojawiać się na początku trajektorii.

2.1. Porównywane warianty

Porównano następujące konfiguracje inwersji:

- **DDIM Inv.** – standardowa inwersja DDIM bez adaptera LoRA.
- **LoRA 1–5 kroków** – adapter LoRA aktywny wyłącznie przez pierwsze $1, \dots, 5$ kroków inwersji, czyli odpowiednio 2%, ..., 10% trajektorii.
- **Pełna LoRA** – adapter aktywny przez wszystkie 50 kroków inwersji.

Adapter był aktywny tylko podczas inwersji. Rekonstrukcja obrazu oraz generowanie obrazu edytowanego były wykonywane bez LoRA. Dzięki temu porównanie mierzy jakość otrzymanego latentu, a nie zmianę samego procesu generacji.

2.2. Normalność latentów i jakość rekonstrukcji

Pierwszym celem było sprawdzenie, czy adapter zmniejsza odchylenie odtworzonego szumu od rzeczywistego szumu początkowego. Do opisu własności latentów wykorzystano średnią korelację Pearsona w patchach 8×8 . Im niższa wartość tej korelacji, tym słabsze lokalne zależności przestrzenne w latencji, a więc tym bliżej zachowuje się on jak niezależnie próbkowany szum gaussowski. Drugą metryką normalności jest dywergencja KL liczona niezależnie dla każdej pozycji latentu i uśredniana po wymiarach.

2.2.1. Pełna aktywacja LoRA

Pierwszym porównaniem jest pełna aktywacja adaptera LoRA dla trzech wariantów rzędu: $r = 8$, $r = 16$ oraz $r = 32$ z inwersją DDIM.


Tabela 2.1. Porównanie adapterów LoRA dla różnych rzędów z inwersją DDIM.

Metoda	Corr. ↓	KL Div. $\times 10^2$ ↓	Recon. MAE ↓	LPIPS ↓	PSNR ↑	SSIM ↑
DDIM Inv.	0.1601	0.8566	0.02663	0.09617	28.32	0.8112
$r = 8, \alpha = 4$	0.0999	0.0767	0.02063	0.05982	30.06	0.8654
$r = 16, \alpha = 8$	<u>0.0989</u>	<u>0.0671</u>	<u>0.02028</u>	<u>0.05774</u>	<u>30.22</u>	<u>0.8699</u>
$r = 32, \alpha = 16$	0.0972	0.0504	0.01970	0.05538	30.40	0.8743

Najlepsze wyniki dla pełnej aktywacji uzyskał adapter $r = 32$. W porównaniu z $r = 16$ zmniejsza on korelację z 0.0989 do 0.0972, KL Div. $\times 10^2$ z 0.0671 do 0.0504. Jednocześnie poprawia metryki rekonstrukcji: Recon. MAE spada do 0.01970, LPIPS[7] do 0.05538, PSNR rośnie do 30.40, a SSIM do 0.8743. Wariant $r = 16$ jest drugim najlepszym ustawieniem w większości metryk, natomiast $r = 8$ daje najslabszą, ale nadal wyraźną poprawę względem DDIM Inv.

Rysunek 2.1 przedstawia przykładowe wyniki rekonstrukcji. W każdej grupie lewa kolumna pokazuje obraz źródłowy, środkowa kolumna rekonstrukcję po standardowej inwersji DDIM, a prawa kolumna rekonstrukcję po inwersji z adapterem LoRA $r = 32$.

2. Wyniki eksperymentów



Obraz źródłowy

DDIM Inv.

LoRA $r = 32$

Rysunek 2.1. Porównanie rekonstrukcji dla standardowej inwersji DDIM i LoRA $r = 32$.

2.2.2. Aktywacja LoRA w pierwszych krokach

Po pełnej aktywacji sprawdzono, czy adapter musi działać przez całą trajektorię inwersji. W tym eksperymencie LoRA była aktywna tylko na początku trajektorii, a następne kroki wykonywano już zwykłym modelem bazowym. Dla każdego rzędu adaptera dostępne są wyniki dla pierwszych pięciu kroków oraz dla pełnej aktywacji.

Tabela 2.2. DDIM Inv., aktywacja LoRA w pierwszych krokach oraz pełna aktywacja LoRA dla adapterów $r = 8$, $r = 16$ oraz $r = 32$.

Adapter	Kroki LoRA	Corr. ↓	KL Div. $\times 10^2$ ↓	Recon. MAE ↓	LPIPS ↓	PSNR ↑	SSIM ↑
DDIM Inv.	0	0.1601	0.8566	0.02663	0.09617	28.32	0.8112
$r = 8$	1	0.1590	0.8499	0.02654	0.09546	28.34	0.8123
$r = 8$	2	0.1204	0.3891	0.02508	0.08507	28.65	0.8304
$r = 8$	3	0.1129	0.3007	0.02489	0.08416	28.70	0.8337
$r = 8$	4	0.1097	0.2582	0.02482	0.08391	28.71	0.8349
$r = 8$	5	0.1078	0.2327	0.02481	0.08393	28.71	0.8353
$r = 8$	50	0.0999	0.0767	0.02063	0.05982	30.06	0.8654
$r = 16$	1	0.1588	0.8499	0.02654	0.09551	28.34	0.8122
$r = 16$	2	0.1180	0.3584	0.02508	0.08475	28.64	0.8312
$r = 16$	3	0.1105	0.2687	0.02486	0.08366	28.69	0.8347
$r = 16$	4	0.1076	0.2302	0.02479	0.08340	28.71	0.8359
$r = 16$	5	0.1059	0.2075	0.02478	0.08346	28.70	0.8363
$r = 16$	50	<u>0.0989</u>	<u>0.0671</u>	<u>0.02028</u>	<u>0.05774</u>	<u>30.22</u>	<u>0.8699</u>
$r = 32$	1	0.1588	0.8486	0.02653	0.09536	28.34	0.8124
$r = 32$	2	0.1143	0.3397	0.02497	0.08402	28.67	0.8325
$r = 32$	3	0.1071	0.2502	0.02474	0.08283	28.72	0.8363
$r = 32$	4	0.1043	0.2096	0.02466	0.08250	28.74	0.8377
$r = 32$	5	0.1028	0.1861	0.02463	0.08249	28.74	0.8382
$r = 32$	50	0.0972	0.0504	0.01970	0.05538	30.40	0.8743

Największy skok jakości pojawia się po przejściu z jednego do dwóch kroków. Jeden krok prawie nie zmienia wyniku DDIM Inv., natomiast dwa kroki wyraźnie zmniejszają korelację latentów i jednocześnie poprawiają rekonstrukcję. Najmocniej widać to dla $r = 32$: korelacja spada z 0.1601 do 0.1143, KL Div. $\times 10^2$ z 0.8566 do 0.3397, a PSNR rośnie z 28.32 do 28.67. Dalsze zwiększanie liczby kroków z aktywną LoRA daje mniejsze, ale nadal stabilne zyski. Wariant $r = 32$ aktywny przez pięć kroków osiąga Corr. 0.1028, KL Div. $\times 10^2$ równe 0.1861, PSNR 28.74 i SSIM 0.8382.

Pełna aktywacja $r = 32$ pozostaje najlepsza liczbowo w tym zestawieniu. W porównaniu z DDIM Inv. korelacja latentów spada o około 39%, KL Div. $\times 10^2$ o około 94%, Recon. MAE o około 26%, a LPIPS o około 42%. Równocześnie PSNR wzrasta z 28.32 do 30.40, a SSIM z 0.8112 do 0.8743. Aktywacja tylko w pierwszych krokach jest jednak istotna praktycznie:

już pierwsze dwa do pięciu kroków przejmują dużą część poprawy normalności latentów, bez pogorszenia metryk rekonstrukcji.

2.3. Porównanie z forward diffusion

Punktem odniesienia dla aktywacji LoRA w pierwszych krokach jest wariant, w którym pierwsze kroki inwersji zastępowane są zwykłą dyfuzją w przód. Zestawienie wykonano dla dwóch i pięciu kroków aktywnej LoRA oraz dla pełnej aktywacji każdego rzędu adaptera.

Tabela 2.3. Porównanie aktywacji LoRA w pierwszych krokach z wariantem forward diffusion.

Metoda	Corr. ↓	KL Div. $\times 10^2$ ↓	Recon. MAE ↓	LPIPS ↓	PSNR ↑
DDIM Inv.	0.1601	0.8566	0.02663	0.09617	28.32
Forward 2%	0.1400	0.7100	0.03000	0.10000	27.12
Forward 4%	0.0900	0.3800	0.04000	0.14000	25.68
LoRA $r = 8$, 2 kroki	0.1204	0.3891	0.02508	0.08507	28.65
LoRA $r = 8$, 5 kroków	0.1078	0.2327	0.02481	0.08393	28.71
Pełna LoRA $r = 8$	0.0999	0.0767	0.02063	0.05982	30.06
LoRA $r = 16$, 2 kroki	0.1180	0.3584	0.02508	0.08475	28.64
LoRA $r = 16$, 5 kroków	0.1059	0.2075	0.02478	0.08346	28.70
Pełna LoRA $r = 16$	0.0989	<u>0.0671</u>	<u>0.02028</u>	<u>0.05774</u>	<u>30.22</u>
LoRA $r = 32$, 2 kroki	0.1143	0.3397	0.02497	0.08402	28.67
LoRA $r = 32$, 5 kroków	0.1028	0.1861	0.02463	0.08249	28.74
Pełna LoRA $r = 32$	<u>0.0972</u>	0.0504	0.01970	0.05538	30.40

Forward diffusion skutecznie zmniejsza lokalne korelacje w latencji, ale robi to przez dodanie losowości, co pogarsza rekonstrukcję. Dla wariantu Forward 4% korelacja spada do 0.0900, ale Recon. MAE rośnie do 0.04, LPIPS do 0.14, a PSNR spada do 25.68. LoRA zachowuje korzystniejszy kompromis we wszystkich trzech rzędach adaptera: warianty pięciokrokowe zmniejszają korelację i KL, a jednocześnie utrzymują lepszą rekonstrukcję niż DDIM Inv. Pełna LoRA $r = 32$ osiąga najlepsze metryki rekonstrukcyjne i najniższą dywergencję KL w tym zestawieniu, natomiast pełna LoRA $r = 16$ jest drugim najlepszym wariantem w metrykach rekonstrukcji.

2.4. Znaczenie pierwszych kroków inwersji

Największy wpływ na jakość inwersji mają pierwsze kroki trajektorii. Wyniki dla wszystkich trzech rzędów adaptera pokazują, że pierwsze dwa kroki dają największą część poprawy względem DDIM Inv., natomiast aktywacja adaptera przez pięć pierwszych kroków przejmuje większość zysku pełnej LoRA w metrykach normalności latentów i edycji tekstowej.

Tabela 2.4. Udział poprawy pełnej LoRA uzyskany przez aktywację adaptera w pierwszych pięciu krokach. Dla metryk minimalizowanych liczono spadek wartości, a dla metryk maksymalizowanych wzrost wartości.

Metryka	$r = 8$	$r = 16$	$r = 32$	Średnia
Corr.	86.9%	88.4%	91.1%	88.8%
KL Div. $\times 10^2$	80.0%	82.2%	83.2%	81.8%
Recon. MAE	30.4%	29.2%	28.8%	29.5%
LPIPS	33.7%	33.1%	33.6%	33.4%
CLIP Source	69.5%	70.7%	73.2%	71.1%
CLIP Target	81.7%	81.2%	82.7%	81.9%
Directional CLIP	88.4%	88.0%	91.9%	89.5%

Wariant pięciokrokowy przejmuje średnio 88.8% poprawy pełnej LoRA dla korelacji oraz 81.8% poprawy dla dywergencji KL. Podobny efekt widać w metrykach edycyjnych: średni udział poprawy wynosi 81.9% dla CLIP[8] Target oraz 89.5% dla Directional CLIP[9].

Udział poprawy dla metryk rekonstrukcyjnych jest niższy i wynosi średnio 29.5% dla Recon. MAE oraz 33.4% dla LPIPS. Oznacza to, że pierwsze kroki są kluczowe dla usuwania nienaturalnej struktury z odtworzonego szumu, natomiast późniejsze kroki nadal mają znaczenie dla dokładności rekonstrukcji obrazu. Ten wynik sugeruje praktyczny kompromis jakościowy: aktywacja LoRA tylko w pierwszych krokach może być wystarczająca, gdy priorytetem jest edytowalność i normalność latentów, natomiast pełna LoRA jest korzystniejsza, gdy najważniejsza jest maksymalna jakość rekonstrukcji.

2.5. Regiony jednorodne i niejednorodne

Dodatkowo sprawdzono, czy błąd inwersji różni się pomiędzy obszarami jednorodnymi wizualnie i obszarami zawierającymi więcej lokalnej struktury. W tym celu obraz podzielono na regiony *plain* i *non-plain*. Wyniki pokazują, że błąd w regionach jednorodnych jest większy, a odchylenie standardowe latentów jest tam niższe.

2. Wyniki eksperymentów

Tabela 2.5. Błąd i odchylenie standardowe odtworzonego szumu w regionach jednorodnych i niejednorodnych.

Metoda	Plain error ↓	Non-plain error ↓	Plain std. → 1	Non-plain std. → 1
DDIM Inv.	0.1956	0.1682	0.8770	0.9573
LoRA $r = 8$, 1 krok	0.1937	0.1667	0.8773	0.9576
LoRA $r = 8$, 2 kroki	0.1305	0.1204	0.9082	0.9750
LoRA $r = 8$, 3 kroki	0.1196	0.1120	0.9162	0.9801
LoRA $r = 8$, 4 kroki	0.1148	0.1083	0.9203	0.9830
LoRA $r = 8$, 5 kroków	0.1121	0.1061	0.9230	0.9849
Pełna LoRA $r = 8$	0.1015	0.0970	0.9433	1.0022
LoRA $r = 16$, 1 krok	0.1937	0.1667	0.8773	0.9576
LoRA $r = 16$, 2 kroki	0.1267	0.1175	0.9104	0.9764
LoRA $r = 16$, 3 kroki	0.1155	0.1088	0.9188	0.9819
LoRA $r = 16$, 4 kroki	0.1109	0.1052	0.9228	0.9847
LoRA $r = 16$, 5 kroków	0.1083	0.1031	0.9252	0.9865
Pełna LoRA $r = 16$	<u>0.0982</u>	<u>0.0944</u>	<u>0.9442</u>	<u>1.0029</u>
LoRA $r = 32$, 1 krok	0.1934	0.1664	0.8774	0.9576
LoRA $r = 32$, 2 kroki	0.1222	0.1140	0.9122	0.9776
LoRA $r = 32$, 3 kroki	0.1107	0.1052	0.9208	0.9832
LoRA $r = 32$, 4 kroki	0.1058	0.1014	0.9251	0.9862
LoRA $r = 32$, 5 kroków	0.1031	0.0992	0.9278	0.9882
Pełna LoRA $r = 32$	0.0930	0.0906	0.9479	1.0055

Adapter zmniejsza błąd w obu typach regionów oraz przesuwa odchylenie standardowe w kierunku wartości 1.0. Największa poprawa ponownie pojawia się po przejściu z jednego do dwóch kroków aktywnej LoRA, niezależnie od rzędu adaptera. Najsilniejszy efekt daje $r = 32$, natomiast $r = 16$ jest bardzo bliski w wariancie pełnej aktywacji. Wynik ten jest spójny z obserwacjami przedstawionymi w pracy *There and Back Again*[10], gdzie autorzy wskazują, że problem korelacji i przenoszenia struktury obrazu do odtworzonego szumu jest szczególnie widoczny w obszarach jednorodnych wizualnie. W naszym eksperymencie adapter częściowo ogranicza ten efekt, zmniejszając błąd zarówno w regionach *plain*, jak i *non-plain*.

2.6. Edycja tekstowa

Trzeci blok ewaluacji dotyczył przydatności latentów do edycji obrazów. W tym eksperymencie, po inwersji, obraz był generowany z promptem docelowym. Prompty docelowe utworzono przez cykliczne przesunięcie listy promptów źródłowych o jedną pozycję. Taki protokół pozwala porównać warianty inwersji w tych samych warunkach i sprawdzić, czy uzyskane latenty lepiej reagują na zmianę warunkowania tekstowego.

Tabela 2.6. Metryki CLIP dla edycji tekstowej.

Metoda	CLIP Source ↓	CLIP Target ↑	Directional CLIP ↑
DDIM Inv.	35.08 ± 11.73	67.90 ± 10.92	29.85 ± 7.46
LoRA $r = 8$, 1 krok	35.09 ± 11.73	67.88 ± 10.90	29.85 ± 7.46
LoRA $r = 8$, 2 kroki	33.84 ± 11.77	70.10 ± 10.38	31.22 ± 7.22
LoRA $r = 8$, 3 kroki	33.45 ± 11.79	70.74 ± 10.19	31.53 ± 7.18
LoRA $r = 8$, 4 kroki	33.12 ± 11.76	71.07 ± 10.11	31.71 ± 7.11
LoRA $r = 8$, 5 kroków	32.99 ± 11.72	71.29 ± 10.05	31.80 ± 7.10
Pełna LoRA $r = 8$	32.07 ± 11.82	72.05 ± 9.72	32.05 ± 7.01
LoRA $r = 16$, 1 krok	35.07 ± 11.73	67.89 ± 10.90	29.86 ± 7.45
LoRA $r = 16$, 2 kroki	33.75 ± 11.80	70.24 ± 10.37	31.29 ± 7.20
LoRA $r = 16$, 3 kroki	33.35 ± 11.76	70.82 ± 10.19	31.59 ± 7.16
LoRA $r = 16$, 4 kroki	33.07 ± 11.75	71.21 ± 10.05	31.77 ± 7.14
LoRA $r = 16$, 5 kroków	32.93 ± 11.74	71.33 ± 10.06	31.82 ± 7.11
Pełna LoRA $r = 16$	<u>32.04 ± 11.75</u>	<u>72.13 ± 9.71</u>	32.09 ± 7.04
LoRA $r = 32$, 1 krok	35.09 ± 11.74	67.89 ± 10.89	29.85 ± 7.45
LoRA $r = 32$, 2 kroki	33.75 ± 11.77	70.24 ± 10.38	31.29 ± 7.21
LoRA $r = 32$, 3 kroki	33.24 ± 11.74	70.92 ± 10.13	31.64 ± 7.12
LoRA $r = 32$, 4 kroki	33.02 ± 11.72	71.29 ± 10.08	31.80 ± 7.09
LoRA $r = 32$, 5 kroków	32.83 ± 11.69	71.42 ± 10.00	31.89 ± 7.06
Pełna LoRA $r = 32$	32.00 ± 11.76	72.16 ± 9.76	<u>32.07 ± 7.03</u>

Wyniki są spójne z wcześniejszymi obserwacjami. Warianty LoRA od dwóch kroków wwyż zwiększają CLIP Target oraz Directional CLIP, co oznacza silniejsze dopasowanie do kierunku edycji tekstowej. Pełna LoRA dla wszystkich trzech rzędów osiąga bardzo zbliżone wyniki: najwyższy CLIP Target uzyskuje $r = 32$, a najwyższy Directional CLIP uzyskuje $r = 16$. Jednoczesny spadek CLIP Source wskazuje, że obraz wynikowy w większym stopniu odchodzi od warunkowania źródłowego. W połączeniu ze wzrostem CLIP Target i Directional CLIP sugeruje to większą podatność uzyskanych latentów na zmianę promptu docelowego.

3. Wnioski

Przeprowadzone eksperymenty potwierdzają główną hipotezę projektu: niewielki adapter LoRA używany wyłącznie podczas inwersji może poprawić jakość odtwarzanego

latentu szumowego w DDIM inversion. Adapter zmniejsza lokalne korelacje w odtworzonym szumie, obniża dywergencję KL względem rozkładu normalnego oraz zmniejsza błąd względem rzeczywistego szumu początkowego. Co istotne, poprawa ta nie odbywa się kosztem rekonstrukcji obrazu.

Najważniejszy wynik dotyczy kompromisu pomiędzy normalnością latentów a jakością rekonstrukcji. Zarówno wariant aktywny przez pierwsze kilka kroków, jak i pełna LoRA zmniejszają lokalną strukturę w odtworzonym szumie, a jednocześnie poprawiają metryki rekonstrukcyjne względem bazowej DDIM inversion. Oznacza to, że adapter uczy się użytecznej korekty predykcji szumu, która pozwala uzyskać latent bardziej zbliżony do szumu gaussowskiego bez widocznego kosztu rekonstrukcyjnego.

Wyniki potwierdzają również szczególne znaczenie początkowych kroków inwersji. Już aktywacja LoRA przez pierwsze dwa kroki daje największy pojedynczy przyrost jakości względem DDIM Inv., a pięć pierwszych kroków przejmuje większość zysku pełnej LoRA w metrykach normalności latentów i edytowalności. Jest to zgodne z założeniem, że największy błąd aproksymacji DDIM inversion pojawia się na początku trajektorii.

Porównanie z forward diffusion pokazuje, że poprawa uzyskana przez LoRA ma inny charakter niż proste dodanie losowego szumu. Forward diffusion skutecznie obniża korelacje w latencji, ale pogarsza rekonstrukcję. LoRA natomiast poprawia własności latentów i jednocześnie poprawia metryki rekonstrukcyjne. Sugeruje to, że adapter uczy się użytecznej korekty predykcji szumu, a nie tylko zwiększa losowość odtwarzanego latentu.

W eksperymencie edycji tekstowej warianty LoRA od dwóch kroków wzwyż poprawiają CLIP Target oraz Directional CLIP względem bazowej DDIM inversion. Oznacza to, że uzyskane latenty są bardziej podatne na zmianę promptu docelowego.

Podsumowując, wariant aktywny przez pierwsze kilka kroków stanowi interesujący kompromis pomiędzy normalnością latentów, edytowalnością i jakością rekonstrukcji, szczególnie dla adaptera $r = 32$. W porównaniu rzędów adaptera najlepszą pełną LoRA był wariant $r = 32$, który uzyskał najniższą korelację, najniższą dywergencję KL oraz najlepsze metryki rekonstrukcyjne. Projekt pokazuje, że uczenie korekty predykcji szumu jest sensownym kierunkiem poprawy DDIM inversion i może prowadzić do latentów lepiej nadających się zarówno do rekonstrukcji, jak i do dalszej edycji tekstowej.

Bibliografia

- [1] J. Song, C. Meng i S. Ermon, „Denoising Diffusion Implicit Models”, w *International Conference on Learning Representations*, 2021. adr.: <https://openreview.net/forum?id=St1giarCHLP>.
- [2] D. Podell i in., „SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis”, w *The Twelfth International Conference on Learning Representations*, 2024. adr.: <https://openreview.net/forum?id=di52zR8xgf>.
- [3] E. J. Hu i in., „LoRA: Low-Rank Adaptation of Large Language Models”, w *International Conference on Learning Representations*, 2022. adr.: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [4] X. Li i in., „What If We Recaption Billions of Web Images with LLaMA-3?”, w *Forty-second International Conference on Machine Learning*, 2025. adr.: <https://openreview.net/forum?id=Hntp7s2YfF>.
- [5] J. Ho i T. Salimans, „Classifier-Free Diffusion Guidance”, *CoRR*, t. abs/2207.12598, 2022. DOI: 10.48550/ARXIV.2207.12598. arXiv: 2207.12598. adr.: <https://doi.org/10.48550/arXiv.2207.12598>.
- [6] I. Loshchilov i F. Hutter, „Fixing Weight Decay Regularization in Adam”, *CoRR*, t. abs/1711.05101, 2017. arXiv: 1711.05101. adr.: <http://arxiv.org/abs/1711.05101>.
- [7] R. Zhang, P. Isola, A. A. Efros, E. Shechtman i O. Wang, „The Unreasonable Effectiveness of Deep Features as a Perceptual Metric”, *CoRR*, t. abs/1801.03924, 2018. arXiv: 1801.03924. adr.: <http://arxiv.org/abs/1801.03924>.
- [8] A. Radford i in., „Learning Transferable Visual Models From Natural Language Supervision”, *CoRR*, t. abs/2103.00020, 2021. arXiv: 2103.00020. adr.: <https://arxiv.org/abs/2103.00020>.
- [9] R. Gal, O. Patashnik, H. Maron, G. Chechik i D. Cohen-Or, „StyleGAN-NADA: CLIP-Guided Domain Adaptation of Image Generators”, *CoRR*, t. abs/2108.00946, 2021. arXiv: 2108.00946. adr.: <https://arxiv.org/abs/2108.00946>.
- [10] Ł. Staniszewski, Ł. Kuciński i K. Deja, „There and Back Again: On the relation between Noise and Image Inversions in Diffusion Models”, w *The Fourteenth International Conference on Learning Representations*, 2026. adr.: <https://openreview.net/forum?id=8PaDdLuVKN>.