

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Dokumentacja wstępna projektu ZZSN

Evaluating Diffusion Inversion Methods for Text-Based Image Editing -
Task B

Michał Sadowski, Aleksander Szymczyk

WARSZAWA 2026

1. Opis zadania

Celem projektu jest sprawdzenie, czy można poprawić skuteczność technik inwersji w modelach dyfuzyjnych. Problem obecnych metod polega na tym, że podczas inwersji do obrazu w kroku x_t dodawany jest szum przewidziany dla kroku t , mimo że teoretycznie powinien to być szum odpowiadający krokowi $t + 1$. W praktyce nie da się go jednak przewidzieć wcześniej, dlatego współczesne podejścia zakładają, że szum z kolejnych kroków jest do siebie wystarczająco podobny.

W ramach projektu należy przygotować zbiór danych do fine-tuningu poprzez generowanie próbek z nowoczesnych modeli dyfuzyjnych i zapisywanie pośrednich etapów samplingu, a następnie wytrenować prosty adapter, na przykład z użyciem LoRA [1], który podczas inwersji będzie przewidywał szum z poprzedniego kroku zamiast bieżącego. Dzięki temu możliwe będzie zmniejszenie rozbieżności między procesem samplingu a inwersji.

2. Przegląd literatury

Poniżej przedstawiono analizę dwóch artykułów wskazanych w opisie zadania jako referencje związane z problemem inwersji w modelach dyfuzyjnych.

2.1. There and Back Again: On the Relation Between Noise and Image Inversions in Diffusion Models

Artykuł *There and Back Again: On the Relation Between Noise and Image Inversions in Diffusion Models* [2] analizuje ograniczenia klasycznej inwersji DDIM [3] w modelach dyfuzyjnych, rozumianej jako proces przybliżonego odtwarzania szumu początkowego, z którego mogła powstać dana próbka obrazu. Autorzy pokazują, że latenty otrzymywane w wyniku inwersji nie zachowują własności niezależnego szumu gaussowskiego, lecz zawierają istotne korelacje przestrzenne, szczególnie widoczne w obszarach jednorodnych wizualnie, takich jak niebo, tło czy gładkie powierzchnie. Oznacza to, że odwrócony punkt startowy nie jest równoważny rzeczywistemu szumowi używanemu podczas generacji, lecz częściowo zachowuje strukturę obrazu wejściowego.

Kluczowym wkładem pracy jest wskazanie źródła tego błędu. Autorzy pokazują, że problem wynika głównie z pierwszych kroków inwersji, w których model aproksymuje szum dla kolejnego kroku na podstawie predykcji dostępnej w kroku bieżącym. Analiza wykazuje, że właśnie na wczesnych etapach procesu inwersji błąd aproksymacji jest największy, a przewidywany szum ma zbyt małą różnorodność, szczególnie w regionach gładkich. W efekcie latenty DDIM odchylają się od oczekiwanego rozkładu normalnego i stają się mniej podatne na późniejszą manipulację.

Autorzy pokazują następnie, że opisane odchylenie ma praktyczne konsekwencje dla zadań opartych na inwersji. W szczególności interpolacje wykonywane w przestrzeni latentów DDIM tracą jakość i różnorodność w środkowej części trajektorii, podczas gdy interpolacje pomiędzy prawdziwymi szumami zachowują stabilną jakość. Analogicznie, w zadaniach edycji obrazów latenty uzyskane przez DDIM prowadzą do mniej wyrazistych modyfikacji oraz gorszego dopasowania do promptu docelowego, zwłaszcza gdy zmiana dotyczy obszarów jednorodnych.

W odpowiedzi na ten problem praca proponuje bardzo prostą modyfikację: zastąpienie pierwszych kroków DDIM inversion procesem forward diffusion, czyli dodaniem losowego szumu zamiast polegania na błędnych wczesnych aproksymacjach modelu. Autorzy pokazują, że już podmiana niewielkiego odsetka początkowych kroków wystarcza do skutecznego usunięcia korelacji w latentach, przy jedynie niewielkim pogorszeniu rekonstrukcji obrazu. Dzięki temu otrzymana reprezentacja staje się bardziej zbliżona do rzeczywistego szumu i lepiej nadaje się do dalszej edycji oraz interpolacji.

2.2. Artykuł *Direct Inversion: Boosting Diffusion-Based Editing with 3 Lines of Code*

Artykuł *Direct Inversion: Boosting Diffusion-Based Editing with 3 Lines of Code* [4] dotyczy problemu inwersji w warunkowych modelach dyfuzyjnych wykorzystywanych do edycji obrazów na podstawie promptów tekstowych. W typowym pipeline obraz źródłowy jest najpierw odwracany do przestrzeni zaszumionych latentów, a następnie używany w dwóch gałęziach generacji: jednej odpowiedzialnej za zachowanie kluczowej treści obrazu wejściowego oraz drugiej odpowiadającej za zgodność wyniku z promptem docelowym. Autorzy zauważają, że wcześniejsze metody, takie jak Null-Text Inversion czy StyleDiffusion, próbują znaleźć jedną wspólną reprezentację dla obu tych gałęzi, zwykle za pomocą czasochłonnej optymalizacji. Prowadzi to jednak do kompromisu między rekonstrukcją obrazu, jakością edycji i szybkością działania.

Głównym wkładem pracy jest pokazanie, że obie gałęzie pełnią różne funkcje i nie powinny być traktowane symetrycznie. Na tej podstawie autorzy proponują metodę *Direct Inversion*, która rozdziela ścieżkę źródłową i docelową. Gałąź docelowa pozostaje niezmienną, aby zachować maksymalną zgodność z promptem edycyjnym, natomiast w gałęzi źródłowej w każdym kroku bezpośrednio korygowana jest różnica między trajektorią idealną a rzeczywistą trajektorią inwersji. W praktyce sprowadza się to do bardzo prostej modyfikacji procesu generacji, wymagającej jedynie trzech dodatkowych linii kodu, bez potrzeby wykonywania kosztownej optymalizacji.

Autorzy wprowadzają także benchmark PIE-Bench, zawierający 700 obrazów i 10 typów edycji, co pozwala osobno oceniać zachowanie struktury, jakość tła, zgodność z promptem oraz czas działania metody. W eksperymentach pokazano, że *Direct Inversion* poprawia zarówno zachowanie istotnej treści obrazu, jak i jakość samej edycji, a jednocześnie działa znacznie szybciej niż wcześniejsze metody optymalizacyjne. Praca pokazuje więc, że lepsze wyniki w edycji dyfuzyjnej można osiągnąć nie przez bardziej złożoną inwersję, lecz przez trafniejsze rozdzielenie ról obu gałęzi procesu.

2.3. Wnioski

Z punktu widzenia tego projektu kluczowe znaczenie ma przede wszystkim pierwszy z omówionych artykułów, ponieważ dostarcza on bezpośredniej diagnozy problemu: błąd DDIM inversion wynika z aproksymacji predykcji dla kolejnego kroku przez predykcję z kroku poprzedniego, a największe odchylenia pojawiają się na początku trajektorii. To właśnie z tej obserwacji wynika proponowany w projekcie pomysł uczenia adaptera LoRA, który ma korygować tę “przesuniętą” predykcję podczas inwersji. Drugi artykuł nie stanowi bezpośredniej podstawy proponowanej metody, ale jest przydatny jako uzasadnienie praktyczne: pokazuje, że jakość inwersji ma bezpośredni wpływ na zachowanie struktury obrazu i jakość edycji, a także dostarcza sensownego punktu odniesienia dla późniejszej ewaluacji rozwiązania w zadaniach edycyjnych.

3. Przewidywany sposób rozwiązania problemu

Proponowane rozwiązanie polega na wytrenowaniu niewielkiego adaptera LoRA, używanego wyłącznie podczas inwersji, którego zadaniem będzie skorygowanie błędu aproksymacji występującego w DDIM inversion. Błąd ten wynika z faktu, że podczas odwracania trajektorii model korzysta z predykcji dostępnej dla poprzedniego stanu, mimo że teoretycznie potrzebna jest predykcja odpowiadająca kolejnemu krokowi. Analiza literatury pokazuje, że problem ten jest szczególnie widoczny na początku procesu inwersji, gdzie błąd jest największy, a przewidywany szum ma zbyt małą różnorodność.

W pierwszym etapie zostanie przygotowany zbiór danych do fine-tuningu. Dla każdego wygenerowanego przykładu zapiszemy: prompt tekstowy c , początkowy szum x_T , wszystkie pośrednie stany trajektorii generacji $\{x_t\}$ uzyskane w forward pass oraz odpowiadające im predykcje modelu $\epsilon_\theta(x_t, t, c)$. Dane te będą pochodziły z deterministycznego procesu DDIM, a w celu odizolowania samego błędu inwersji ustawimy współczynnik guidance na $w = 1$, zgodnie z procedurą przyjętą w analizowanej pracy.

Następnie z zapisanej trajektorii zostaną zbudowane pary treningowe. Dla kroku t wejściem będzie stan dostępny podczas inwersji, tj. x_{t-1} wraz z indeksem kroku i promptem, natomiast celem będzie predykcja odpowiadająca kolejnemu punktowi trajektorii, tj. $\epsilon_\theta(x_t, t, c)$. Równoważnie można uczyć adapter reszty

$$\Delta\epsilon_t = \epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_{t-1}, t, c),$$

tak aby podczas inwersji otrzymywać poprawioną predykcję

$$\hat{\epsilon}_t = \epsilon_\theta(x_{t-1}, t, c) + \text{LoRA}(x_{t-1}, t, c).$$

W praktyce oznacza to, że adapter ma nauczyć się przewidywać “przesuniętą” predykcję z następnego kroku, korzystając jedynie z informacji dostępnej o krok wcześniej. Taki sposób uczenia jest zgodny z diagnozą problemu przedstawioną w pracy *There and Back Again*, gdzie błąd inwersji definiowany jest właśnie jako różnica między predykcją dla x_{t-1} i predykcją dla rzeczywistego x_t .

Dodatkowo planowane jest sprawdzenie wariantu, w którym adapter LoRA działa tylko dla początkowego procentu kroków inwersji, na przykład dla pierwszych 2% – 10% trajektorii. Jest to uzasadnione obserwacją, że największa część błędu kumuluje się właśnie na wczesnych etapach procesu, a niewielka ingerencja w początkowe kroki może wystarczyć do poprawy jakości latentów bez istotnego pogorszenia rekonstrukcji.

Ewaluacja proponowanej metody będzie obejmowała trzy aspekty. Po pierwsze, oceniona zostanie jakość rekonstrukcji obrazu po inwersji i ponownej generacji, z użyciem metryk takich jak MAE, LPIPS, SSIM oraz PSNR. Po drugie, sprawdzone zostaną własności otrzymanych latentów, w szczególności stopień ich korelacji i odchylenia od rozkładu

3. Przewidywany sposób rozwiązania problemu

gaussowskiego, analogicznie do analizy przedstawionej w pracy *There and Back Again*. Po trzeciej, oceniona zostanie przydatność latentów w zadaniach edycji obrazu, między innymi za pomocą podobieństwa CLIP do promptu docelowego oraz metryk percepcyjnych porównujących obraz źródłowy i edytowany. Wyniki zostaną porównane z naiwną DDIM inversion oraz z wariantami, w których adapter LoRA działa we wszystkich krokach albo tylko w początkowym fragmencie trajektorii.

4. Założenia

4.1. Typ modelu

Podstawowym modelem wykorzystywanym w projekcie będzie **Stable Diffusion XL (SDXL)** [5], czyli warunkowy model dyfuzyjny działający w przestrzeni latentów. Wariantem opcjonalnym, użytym do dodatkowych eksperymentów porównawczych, może być **DeepFloyd IF** [6], czyli model działający w przestrzeni pikseli. W obu przypadkach generacja i inwersja będą realizowane z użyciem deterministycznego samplera DDIM.

4.2. Wybrane zbiory danych

Do przygotowania zbioru treningowego wykorzystane zostaną prompty z **Recap-COCO-30K** [7]. Na ich podstawie generowane będą obrazy wraz z pełnymi trajektoriami samplingu, które następnie posłużą do budowy par treningowych dla adaptera LoRA. Zbiór ten został również wykorzystany w analizowanej pracy [2] dla modeli IF i SDXL.

4.3. Narzędzia

W projekcie wykorzystane zostaną następujące narzędzia i biblioteki:

- Python
- PyTorch
- Diffusers
- Transformers
- PEFT
- NumPy
- Pandas
- Hydra
- Weights & Biases
- Matplotlib
- Jupyter Notebook

4.4. Zakładana funkcjonalność

Efektom projektu ma być prototyp metody inwersji, w której niewielki adapter LoRA koryguje predykcje modelu wyłącznie podczas odwracania trajektorii DDIM. System powinien umożliwiać: generowanie danych treningowych z zapisaniem pośrednich stanów, trenowanie adaptera dla zadania poprawy inwersji, uruchamianie inwersji z aktywnym lub wyłączonym LoRA oraz porównanie jakości latentów, rekonstrukcji i edycji względem bazowej DDIM inversion. Dodatkowo przewidziana jest możliwość testowania wariantu, w którym korekta działa tylko dla początkowego fragmentu kroków inwersji, ponieważ właśnie tam błąd aproksymacji jest największy.

Bibliografia

- [1] E. J. Hu i in., „LoRA: Low-Rank Adaptation of Large Language Models”, w *International Conference on Learning Representations*, 2022. adr.: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [2] Ł. Staniszewski, Ł. Kuciński i K. Deja, „There and Back Again: On the relation between Noise and Image Inversions in Diffusion Models”, w *The Fourteenth International Conference on Learning Representations*, 2026. adr.: <https://openreview.net/forum?id=8PaDdLuVKN>.
- [3] J. Song, C. Meng i S. Ermon, „Denoising Diffusion Implicit Models”, w *International Conference on Learning Representations*, 2021. adr.: <https://openreview.net/forum?id=St1giarCHLP>.
- [4] X. Ju, A. Zeng, Y. Bian, S. Liu i Q. Xu, *Direct Inversion: Boosting Diffusion-based Editing with 3 Lines of Code*, 2023. arXiv: 2310.01506 [cs.CV]. adr.: <https://arxiv.org/abs/2310.01506>.
- [5] D. Podell i in., „SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis”, w *The Twelfth International Conference on Learning Representations*, 2024. adr.: <https://openreview.net/forum?id=di52zR8xgf>.
- [6] Stability AI, *DeepFloyd IF: a novel state-of-the-art open-source text-to-image model with a high degree of photorealism and language understanding*, <https://github.com/deep-floyd/IF>, Retrieved on 2023-04-17, 2023.
- [7] X. Li i in., „What If We Recaption Billions of Web Images with LLaMA-3?”, *arXiv preprint arXiv:2406.12345*, 2024.